Imię i Nazwisko: Błażej Klepacki	**Kierunek:** MAD	**PUNKTACJA**
Prowadzący: AK	**Numer albumu:** 331389	/ 8

Raport z Kamienia Milowego 1: Eksploracja i przygotowanie danych

1 Eksploracyjna analiza danych

Zbiór treningowy ma 6400 obserwacji i 23 cechy (bez duplikatów), a testowy 1600 obserwacji. Zmienna docelowa to zwłoka w płatności w kolejnym miesiącu, która dotyczy 21,6% klientów (1381 z 6400), więc klasy są niezbalansowane. `SEX`, `EDUCATION` i `MARRIAGE` są kategoryczne (zapisane jako liczby), a pozostałe cechy liczbowe. Kwoty (`BILL_AMT`, `PAY_AMT`) mają mocno prawoskośne rozkłady, a w `PAY_*` większość wartości to -2, -1 lub 0 (w `PAY_0` około 78%). Wartości dodatnie `PAY_*` oznaczają opóźnienie w miesiącach (tak jest w oryginalnym zbiorze UCI, w poleceniu nie jest to rozpisane).

1.1 Braki danych

Braki są w trzech kolumnach: `PAY_5` (9,9%), `BILL_AMT6` (10,2%) i `PAY_AMT4` (9,9%). Razem dotyczą 27% wierszy (1743 z 6400), więc usuwanie wierszy z brakami odpada. Braki nie są ze sobą skorelowane (korelacja wskaźników braków około 0), a odsetek zwłok jest podobny z brakiem i bez niego (0,22–0,24 wobec 0,21–0,22), więc nie widać zależności od zmiennej docelowej i wyglądają na losowe. W zbiorze testowym braki są w tych samych kolumnach i w podobnej skali (9–10%). Uzupełnieniem zajmę się w pipeline w KM2.

1.2 Wartości odstające

Według reguły $1{,}5 \cdot IQR$ poza wąsami boxplota jest 8–9% obserwacji w każdej kolumnie `BILL_AMT` i `PAY_AMT` (w `LIMIT_BAL` 1%, w `AGE` 0,5%). Skrajne kwoty wyglądają na prawdziwe, duże wartości, więc ich nie usuwam (drzewa są odporne na wartości skrajne). Bardziej podejrzane są wartości ujemne: wpłata nie powinna być ujemna, a `PAY_AMT` ma ich 920–1219 w każdej kolumnie (co najmniej jedna w 57% wierszy). Ujemny jest też jeden `LIMIT_BAL` oraz 833–936 wartości w każdej kolumnie `BILL_AMT`, co przy rachunkach może być nadpłatą. Możliwe, że to szum w danych, więc decyzję podejmę w KM2. Dodatkowo `PAY_3` ma jedną obserwację równą -3 (w innych `PAY_*` minimum to -2), a `EDUCATION` (0, 4, 5, 6) i `MARRIAGE` (0, 3) mają rzadkie wartości oznaczające „inne” (108 i 75 obserwacji).

1.3 Relacje i istotność zmiennych

Ze zmienną docelową najsilniej skorelowana jest historia spłat: `PAY_0` (0,31), `PAY_2` (0,26) i kolejne `PAY_*` (malejąco do 0,17), a z kwot tylko `LIMIT_BAL` ($-0{,}15$). Drzewo o głębokości 5 daje podobny obraz: istotność `PAY_0` to 0,625, `PAY_2` 0,127, a każdej z pozostałych cech poniżej 0,035. Odsetek zwłok rośnie z opóźnieniem: 11–18% dla `PAY_0` ≤ 0, 32% dla 1 i około 68% dla 2 i 3 (rys. 1). Zmienne demograficzne mają słaby związek ze zmienną docelową (np. 24% zwłok u mężczyzn i 20% u kobiet). Kolumny `BILL_AMT` mają z y korelację około 0, za to są silnie skorelowane między sobą (0,79–0,94), czyli współliniowe, co może przeszkadzać modelom liniowym w KM2.

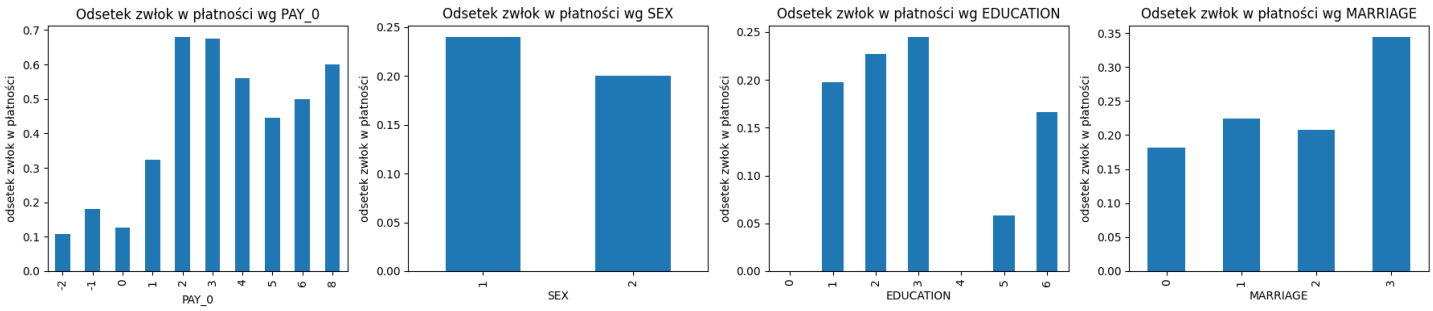


Figure 1: Odsetek zwłok w płatności w grupach wg `PAY_0`, `SEX`, `EDUCATION` i `MARRIAGE`.

2 Metryka ewaluacji i podział danych

Zadanie to klasyfikacja binarna, a wynikiem końcowym ma być wektor prawdopodobieństw klasy 1, więc potrzebuję metryki, która ocenia prawdopodobieństwa, a nie same etykiety. Jako główną metrykę wybieram **ROC AUC**: krzywa ROC to pary (FPR, TPR) dla kolejnych progów odcięcia, a AUC to pole pod nią (0,5 dla klasyfikatora losowego, 1 dla idealnego). Nie zależy od progu i mówi, jak dobrze model układa klientów od najmniej do najbardziej ryzykownych. Klasy są niezbalansowane (21,6% klasy 1), więc accuracy jest mylące: klasyfikator, który zawsze zgaduje klasę 0, ma accuracy 0,784, ale AUC 0,5 i F1 równe 0. Pomocniczo liczę **average precision** (AP), bo jest czulsza, gdy klasa pozytywna jest rzadka, a losowy klasyfikator ma AP równe udziałowi klasy 1 (0,216). Accuracy podaję tylko dla porównania.

2.1 Strategia podziału danych

Zbiór `X_test` nie ma etykiet, więc nie da się na nim niczego ocenić. Dlatego z `X_train` wydzieliłem 20% obserwacji jako zbiór hold-out (1280 obserwacji), stratyfikowany względem y, żeby udział klasy 1 był wszędzie taki sam (21,6%). Hold-out nie służy do doboru hiperparametrów ani modelu, użyję go tylko do końcowej oceny wybranego modelu. Eksploracyjna analiza była robiona na całym `X_train`, ale nie służyła do wyboru modelu ani hiperparametrów. Na pozostałych 80% (5120 obserwacji) dobieram hiperparametry 5-krotną stratyfikowaną walidacją krzyżową (w każdym foldzie 4096 obserwacji uczących i 1024 walidacyjnych, udział klasy 1 wszędzie 21,6%). Wybrałem CV zamiast jednego podziału walidacyjnego, bo pojedynczy podział daje niestabilne wyniki (zauważone na lab 2), a stratyfikację dodałem ze względu na niezbalansowanie klas. Wszystkie `random_state` wynoszą 123, więc wyniki się powtarzają.

3 Optymalizacja hiperparametrów modelu drzewa

Domyślne drzewo się przeucza: ROC AUC wynosi 1,0 na zbiorze uczącym, a w CV tylko 0,61. Wybrałem trzy hiperparametry ograniczające jego złożoność: `max_depth` (maksymalna głębokość), `min_samples_leaf` (minimalna liczba obserwacji w liściu) i `ccp_alpha` (kara za złożoność w przycinaniu cost-complexity). Najpierw sprawdziłem każdy z nich osobno, przy pozostałych domyślnych (rys. 2): ROC AUC w CV rośnie do maksimum, a potem spada, natomiast na zbiorze uczącym rośnie wraz ze złożonością drzewa, czyli rośnie przeuczenie. Na tej podstawie ustaliłem siatkę: `max_depth` $\in \{3, 4, 5, 6, 8, 10, \text{None}\}$, `min_samples_leaf` $\in \{1, 10, 30, 50, 75, 100, 150, 200\}$ i `ccp_alpha` $\in \{0,\ 10^{-4},\ 3\cdot10^{-4},\ 5\cdot10^{-4},\ 10^{-3},\ 2\cdot10^{-3}\}$. Daje to 336 kombinacji, a każdą oceniłem 5-krotną stratyfikowaną CV (ROC AUC, pomocniczo AP). Wartości są gęściej tam, gdzie krzywe osobne mają maksimum.

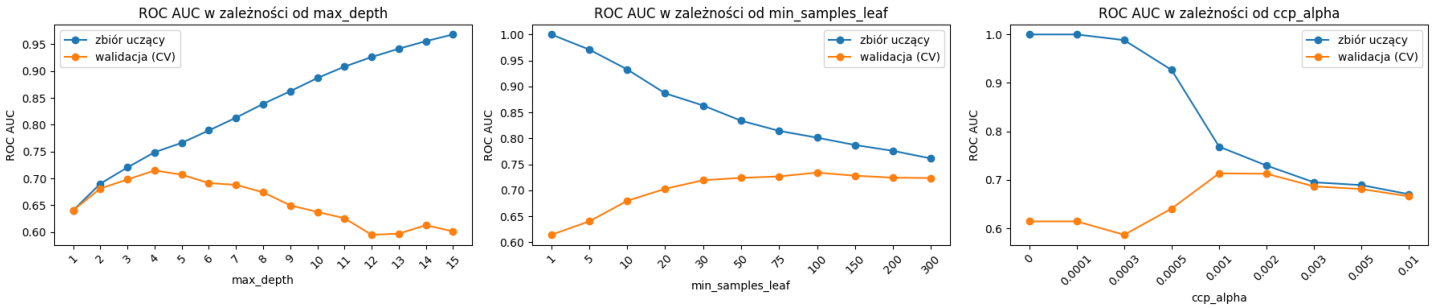


Figure 2: ROC AUC na zbiorze uczącym i w CV w zależności od każdego hiperparametru osobno.

Najlepsza kombinacja to `max_depth=8`, `min_samples_leaf=75`, `ccp_alpha=0,0003` (CV ROC AUC 0,736 ± 0,013, AP 0,490). Najlepsze kombinacje różnią się o mniej niż 0,003, czyli mniej niż odchylenie standardowe między foldami (0,01–0,02), więc wybór wśród nich jest w dużej mierze przypadkowy. Osobno najwięcej poprawia `min_samples_leaf` (z około 0,61 do około 0,73), ale w siatce różne kombinacje dają podobny wynik, bo każdy hiperparametr ogranicza złożoność na swój sposób. Zbyt duże `ccp_alpha` (od 0,001) i zbyt płytkie drzewo (`max_depth`=3, najlepiej 0,706) obniżają wynik. Na hold-oucie wybrane drzewo (głębokość 8, 26 liści) daje ten sam ROC AUC co w CV, więc nie widać przeuczenia przy doborze hiperparametrów:

Model	CV ROC AUC	CV AP	hold-out ROC AUC	hold-out AP	hold-out accuracy
domyślne drzewo	0,614	0,286	0,602	0,275	0,724
drzewo po tuningu	0,736	0,490	0,736	0,469	0,812

4 Podsumowanie i wnioski

Zbiór ma 6400 obserwacji i niezbalansowane klasy (21,6% zwłok), a najważniejszym predyktorem jest historia spłat, przede wszystkim `PAY_0`. W danych są braki w trzech kolumnach (około 10%, wyglądają na losowe), ujemne wpłaty (57% wierszy), rzadkie kategorie „inne” i współliniowe `BILL_AMT`, co zostawiam do rozwiązania w pipeline'ie w KM2. Jako metrykę wybrałem ROC AUC (pomocniczo AP), a dane podzieliłem na stratyfikowany hold-out 20% i 5-krotną stratyfikowaną CV na reszcie. Po strojeniu trzech hiperparametrów drzewo z `max_depth=8`, `min_samples_leaf=75` i `ccp_alpha=0,0003` ma ROC AUC 0,736 (w CV i na hold-oucie), czyli o około 0,13 więcej niż drzewo domyślne na hold-oucie. Ograniczenia: najlepsze kombinacje różnią się o mniej niż 0,003, więc ich kolejność jest mało pewna, a hold-out ma tylko 1280 obserwacji (około 276 z klasą 1). W KM2 uzupełnię braki, zdecyduję, co zrobić z ujemnymi wpłatami i kategoriami „inne”, i dodam drugi model (np. regresję logistyczną z lab 4).